

Прогнозирование энергопотребления зданий

Почасовой прогноз по характеристикам здания, погодным условиям и временным признакам: EDA, классические модели, MLP и ансамблирование.

20.2 млн	1.313	1.251
строк train	лучший validation RMSLE	Kaggle public score

Краткое резюме

Цель проекта - предсказать meter_reading для четырёх типов счётчиков по характеристикам здания, погоде и времени. Из-за тяжёлого правого хвоста целевая переменная преобразована через log1p; RMSE в логарифмическом пространстве соответствует RMSLE на исходной шкале.

Лучшая отдельная baseline-модель - XGBoost со средним CV RMSLE 1.378. На общем временном holdout MLP достигла 1.343, а stacking из Ridge, LightGBM, XGBoost и MLP улучшил результат до 1.313. Итоговый public score на Kaggle равен 1.251.

Ключевой результат: public score снизился с 2.137 у Dummy до 1.452 у XGBoost и до 1.251 у stacking.

Параметр	Значение
Задача	Регрессия почасового энергопотребления
Метрика	RMSLE
Данные	Здания, тип счётчика, погода, время
Инструменты	Python, scikit-learn, boosting, PyTorch


01 Данные, EDA и предобработка

Данные объединяются из пяти таблиц по `building_id`, `site_id` и `timestamp`. Основная обучающая таблица содержит 20 216 100 наблюдений; `test` - 41 697 600. Признаки включают идентификаторы и назначение здания, площадь, год постройки, этажность, тип счётчика и погодные измерения.

Таблица	Строк	Назначение
train.csv	20 216 100	Показания счётчиков
test.csv	41 697 600	Тестовые наблюдения
building_metadata	1 449	Характеристики зданий
weather_train	139 773	Порода train
weather_test	277 243	Порода test

Наблюдения EDA

- Цель сильно скошена вправо: медиана 78.8, среднее 2 117, максимум 21.9 млн.
- Медианы по типам счётчиков различаются от 39.6 до 257.8.
- Площадь связана с потреблением положительно, но разброс велик.
- Погодные корреляции с целью слабы линейно, однако зависимости нелинейны.
- Суточные профили различаются по назначению здания.



Предобработка

Память исходных таблиц снижена с 3047.6 MB до 900.4 MB за счёт компактных типов. Числовые пропуски для Ridge, Decision Tree, XGBoost и MLP заполняются медианой, категориальные - наиболее частым значением. LightGBM использует встроенную обработку NaN. Экстремальные значения цели не удаляются как потенциально валидные; их влияние уменьшается преобразованием $\log_{10}$.

Контроль leakage: split выполняется до fit preprocessing; rolling-признак строится как `shift(1).rolling(24)`, поэтому текущее и будущее значения не попадают в признак.

02 Валидация и классические модели

Наблюдения имеют временную структуру, поэтому случайное перемешивание могло бы перенести информацию из будущего в прошлое. Используется TimeSeriesSplit по уникальным timestamp: все строки одного часа целиком относятся либо к train, либо к validation, а обучающий диапазон последовательно расширяется.




Интерпретация

Бустинги существенно превосходят линейные модели, поскольку энергопотребление зависит от нелинейных взаимодействий между зданием, счётчиком, погодой и временем. XGBoost дал минимальный RMSLE, но LightGBM обучается примерно вдвое быстрее при разнице качества около 0.01. Decision Tree менее устойчив между фолдами; одиночному дереву не хватает усреднения и регуляризации ансамбля.

Практический выбор: XGBoost - максимум качества среди baseline-моделей; LightGBM - почти то же качество при заметно меньшем времени обучения.

03 Feature engineering и MLP

Исследованы календарные, циклические, строительные и погодные признаки: month, is_weekend, hour_sin/hour_cos, day_of_week_sin/day_of_week_cos, log_square_foot, temp_dew_diff, heating_degree, cooling_degree, а также лаги температуры на 1, 24 и 168 часов и rolling mean за 24 часа.



Ablation показал устойчивое улучшение от циклического часа: RMSLE снизился для LightGBM на 0.0245, XGBoost на 0.0095, Ridge на 0.0062 и Decision Tree на 0.0055. Лаги температуры не дали устойчивого выигрыша; rolling_24 ухудшал tree-based модели. Финальный набор дополнений: hour_sin, hour_cos, is_weekend.

Архитектура MLP


Компонент	Реализация	Обоснование
Категории	Embeddings: 32 / 3 / 5 / 5	Компактнее one-hot для building_id
Скрытые слои	256 -> 128 -> 64 -> 1	Постепенное сжатие представления
Активация	ReLU	Стабильный градиент и нелинейность
Регуляризация	BatchNorm, Dropout 0.2/0.1, WD	Снижение overfit
Оптимизация	AdamW, lr=1e-3, MSE	Weight decay встроен в optimizer

Лучший validation RMSLE MLP равен 1.329 на 6-й эпохе. После этого train продолжает улучшаться, а validation ухудшается, поэтому early stopping корректно возвращает веса лучшей эпохи.

04 Подбор параметров, ансамбли и итоговое сравнение

Из-за размера исходного набора Random Search через ParameterSampler выполнялся на 2% раннего train-периода и 10% более позднего validation-периода. Временной порядок сохранён.


Модель	Лучшие параметры	Validation RMSLE
Ridge	alpha=10	1.558
LightGBM	500 trees; lr=0.03; leaves=63; depth=8	1.350
XGBoost	500 trees; lr=0.03; depth=10; subsample=0.7	1.379



Модель	RMSLE	Train, с	Predict, с
Stacking	1.313	60.68	5.13
Blending	1.317	60.68	5.12
MLP	1.343	36.40	1.95
LightGBM	1.350	9.10	2.06
XGBoost	1.379	11.01	0.82
Ridge	1.558	4.18	0.29
DecisionTree	1.631	4.29	0.18
Dummy	2.036	0.00	0.00

Stacking обучает Ridge meta-model на out-of-sample предсказаниях отдельного meta_train. Базовые модели не видят target meta_train, поэтому схема не создаёт прямой утечки. Ансамбль выигрывает, потому что бустинги, линейная модель и MLP совершают неодинаковые ошибки. По сравнению с Dummy итоговый RMSLE на общем holdout снижен примерно на 35.5%.

05 Результаты Kaggle и выводы



Public score

Dummy: 2.137
XGBoost baseline: 1.452
Stacking: 1.251
XGBoost улучшил public score относительно Dummy на 32.1%. Stacking дополнительно снизил ошибку XGBoost на 13.8%.

Основные выводы

- 1. Временные закономерности и идентичность здания важнее слабых линейных погодных корреляций.
- 2. Циклическое представление часа устойчиво улучшает все проверенные семейства моделей.
- 3. Бустинги лучше линейных моделей за счёт нелинейных взаимодействий; LightGBM даёт лучший баланс качества и скорости.
- 4. MLP с embeddings конкурентоспособна и добавляет ансамблю разнообразие ошибок.
- 5. Stacking обеспечивает лучший validation RMSLE и лучший public score, объединяя разные структуры ошибок.

Практическая интерпретация

Dummy показывает нижнюю границу качества и не учитывает различия между зданиями и типами счётчиков. XGBoost моделирует нелинейные взаимодействия и резко снижает ошибку. Stacking улучшает результат ещё сильнее, поскольку meta-model адаптивно объединяет прогнозы Ridge, LightGBM, XGBoost и MLP.

Итоговый выбор

Для максимального качества выбран stacking. Если приоритетом является скорость и простота эксплуатации, разумной альтернативой остаётся LightGBM: его качество близко к XGBoost, а обучение заметно быстрее.

Сценарий	Рекомендуемая модель	Причина
Максимум качества	Stacking	Лучший validation и public score
Баланс качества и скорости	LightGBM	Низкий RMSLE и быстрое обучение
Простой сильный baseline	XGBoost	Лучший результат baseline CV